Análisis de supervivencia sobre quimioterapia en cáncer de cólon

De Silva Nacenta Nicolás, Rodríguez Donato Israel y García Maya Ximena

20 de octubre de 2026

Análisis descriptivo

Table 1: Características basales por brazo de tratamiento (n y porcentaje sobre datos disponibles)

Variable	Total	Obs	Lev	Lev+5FU
n	929	315	310	304
sex: male	484 (52%)	166 (53%)	177 (57%)	141 (46%)
age (años), mediana [Q1, Q3]	61 [53, 69]	60 [53, 68]	61 [53, 69]	62 [52, 70]
nodes, mediana [Q1, Q3]	2 [1, 5]	2 [1, 5]	2 [1, 5]	2 [1, 4]
obstruct: 1	180 (19%)	63 (20%)	63 (20%)	54 (18%)
perfor: 1	27 (3%)	9 (3%)	10 (3%)	8 (3%)
adhere: 1	135 (15%)	47 (15%)	49 (16%)	39 (13%)
surg: long	247 (27%)	91 (29%)	80 (26%)	76 (25%)
node4: 1	255 (27%)	87 (28%)	89 (29%)	79 (26%)
differ: well	93 (10%)	27 (9%)	37 (12%)	29 (10%)
differ: moderate	663 (73%)	229 (74%)	219 (73%)	215 (72%)
differ: poor	150 (17%)	52 (17%)	44 (15%)	54 (18%)
extent: submucosa	21 (2%)	8 (3%)	3 (1%)	10 (3%)
extent: muscle	106 (11%)	38 (12%)	36 (12%)	32 (11%)
extent: serosa	759 (82%)	249 (79%)	259 (84%)	251 (83%)
extent: cont.str	43 (5%)	20 (6%)	12 (4%)	11 (4%)

`nodes`: 18 faltantes; `differ`: 23 faltantes.

Se analizaron 929 pacientes, con 452 muertes (48.7%) y 477 censuras; los tres brazos son similares en las covariables basales (Tabla 1). La mediana de supervivencia por Kaplan-Meier fue de 2552 días (IC 95%: 2171 a no alcanzado) y el seguimiento mediano, por Kaplan-Meier invertido, de 2352 días. La mayoría de las censuras ocurre tarde (mediana de 2331 días), lo que es compatible con censura administrativa. Como muestra la Figura 1, Lev+5FU tiene mayor supervivencia: a 2000 días S(t) fue 0.62, contra 0.51 en Obs y 0.51 en Lev, y su mediana no se alcanzó. El log-rank rechaza la igualdad de los tres brazos ($p = 0.003$) y de Obs contra Lev+5FU ($p = 0.002$; sin ajuste por comparaciones múltiples, aunque con Bonferroni la conclusión se mantiene), pero no hay evidencia para rechazar que Obs y Lev sean iguales ($p = 0.81$), lo que motiva unirlos en el modelo de Cox. Faltan 18 valores de `nodes` y 23 de `differ`, sin pacientes en común, y 12 pacientes tienen `nodes` y `node4` mutuamente inconsistentes; como no se sabe cuál es la correcta, se conservaron sin corregir.

1. Modelo paramétrico para el tiempo de supervivencia

Ajustamos a los 929 pacientes, sin covariables, seis distribuciones: exponencial, Weibull, log-normal, log-logística, Gompertz y gamma generalizada (que contiene a varias de las anteriores como casos particulares).

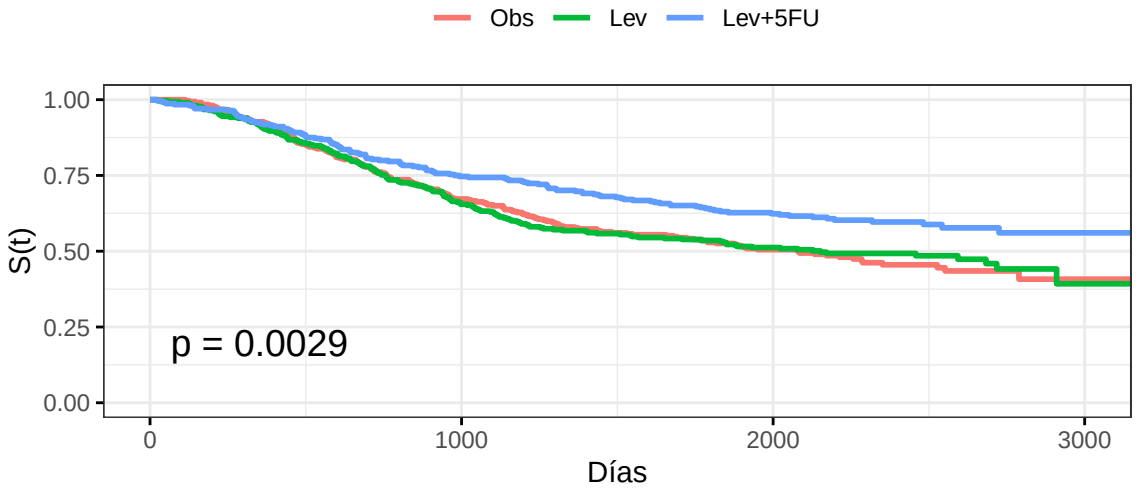


Figure 1: Kaplan-Meier por brazo de tratamiento. Valor p: log-rank de los tres brazos.

Table 2: Comparación de distribuciones (dAIC y dBIC: diferencia contra la mejor)

Distribución	Parámetros	AIC	BIC	dAIC	dBIC
Exponencial	1	8265.4	8270.3	52.5	43.5
Weibull	2	8267.4	8277.1	54.5	50.3
Log-normal	2	8217.1	8226.8	4.2	0.0
Log-logística	2	8236.8	8246.4	23.9	19.6
Gompertz	2	8251.2	8260.8	38.2	34.0
Gamma generalizada	3	8212.9	8227.4	0.0	0.6

Elección de la distribución. Utilizamos criterios de información AIC y BIC, acompañados de las características del riesgo y de la prueba de verosimilitud.

En términos de AIC, el modelo ganador es la gamma generalizada, quedándose a 4.2 puntos la distribución log-normal, por otro lado, en términos de BIC (el cual penaliza más los parámetros extra), se favorece a la distribución log-normal, considerando casi equivalente a la distribución gamma generalizada (diferencia de 0.6, a favor de la log-normal). El resto de distribuciones queda a más de 20 puntos de AIC (de hecho, la exponencial, la más simple, pierde por 53 respecto a la mejor), así que se descartan.

Al analizar las características del riesgo, notamos que la Weibull estima un parámetro de forma de 0.999 (IC 95%: 0.919 a 1.086), es decir, se reduce a la exponencial (riesgo constante), ya que solo permite riesgo creciente, decreciente o constante; sin embargo, los datos parecen favorecer distribuciones que permitan que el riesgo crezca y luego baje (log-normal, gamma generalizada, log-logística).

La prueba de razón de verosimilitud contra la gamma generalizada rechaza la log-normal al 5% ($p = 0.013$), aunque no al 1%, sin embargo, la mejoría (al usar la gamma generalizada) es modesta. Por lo tanto, elegimos la distribución log-normal porque ajusta razonablemente a los datos, es más simple que una distribución gamma generalizada y, la distribución log normal con covariables se interpreta como un modelo de tiempo de vida acelerado, donde las covariables multiplican el tiempo de supervivencia.

Finalmente, debemos reconocer que ningún modelo paramétrico termina por reproducir exactamente la estimación con Kaplan Meier.

Table 3: Log-normal: estimadores de máxima verosimilitud y mediana

	Estimador	IC inf. 95%	IC sup. 95%
meanlog	7.78	7.66	7.89
sdlog	1.43	1.33	1.54
Mediana (días)	2386	2127	2677

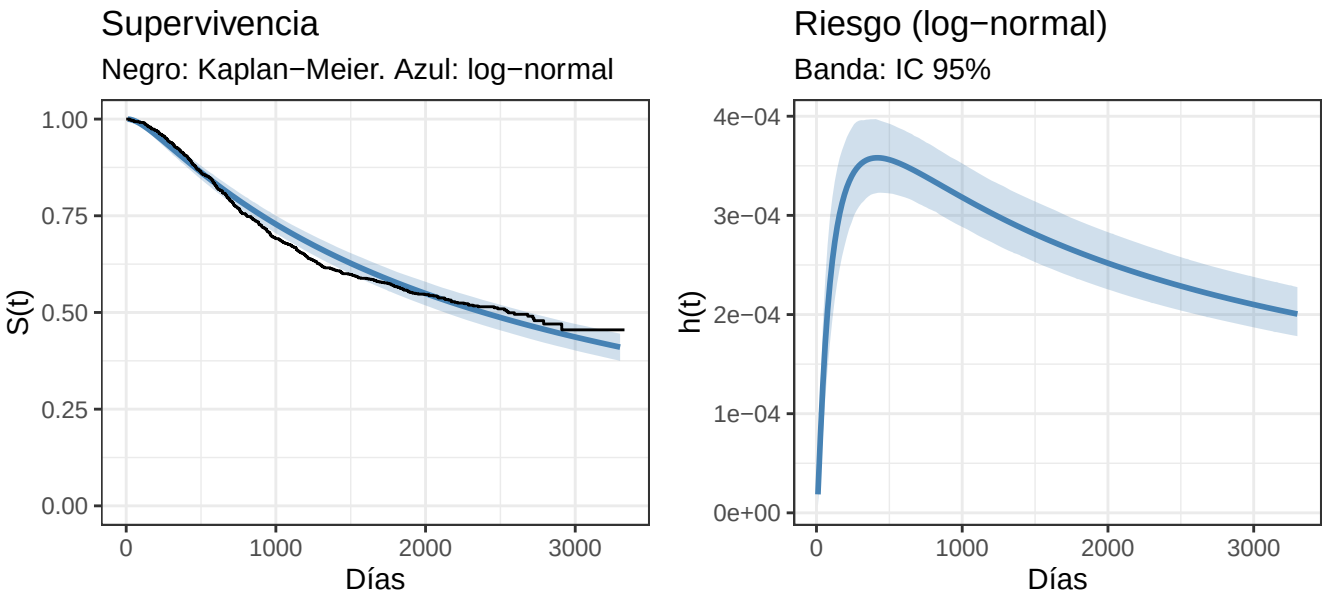


Figure 2: Supervivencia y riesgo estimados (log-normal). Banda: IC 95% por simulación.

Resultados. `meanlog` y `sdlog` son la media y la desviación estándar del logaritmo del tiempo de supervivencia; un `sdlog` de 1.43 indica tiempos muy dispersos. La mediana estimada es 2386 días (aprox. 6.5 años), con IC 95% de 2127 a 2677; este intervalo sale de transformar el de `meanlog`, porque la mediana es exp(meanlog).

El riesgo estimado sube rápido, alcanza su máximo cerca de los 423 días (aprox. 1.2 años) y después baja lentamente. La banda es ancha cerca del día 0 porque probablemente hay pocos eventos tempranos, y no hay datos después de ~3300 días, así que no debe extrapolarse la caída. Los IC de S(t) y h(t) se obtuvieron por simulación (1000 réplicas, semilla fija).

La curva de Kaplan-Meier queda cerca de la log-normal, con una desviación moderada entre ~800 y ~1500 días, donde la log-normal sobrestima la supervivencia hasta unos 0.04.

2. Estimador de Kaplan–Meier y comparación con el modelo paramétrico

Se ajusta el estimador de Kaplan–Meier (KM), que no supone ninguna forma para $S(t)$, y se compara con la supervivencia estimada por el modelo log-normal del punto anterior (sin covariables, 929 pacientes). El KM se usa como referencia para evaluar si el modelo paramétrico describe adecuadamente los datos.

Table 4: Supervivencia estimada: Kaplan-Meier vs. log-normal

Días	KM	KM_inf	KM_sup	LN	LN_inf	LN_sup	Dif	LN_en_IC_KM
500	0.861	0.837	0.882	0.862	0.844	0.879	0.001	Sí
1000	0.691	0.660	0.719	0.728	0.705	0.751	0.037	No

Días	KM	KM_inf	KM_sup	LN	LN_inf	LN_sup	Dif	LN_en_IC_KM
1500	0.598	0.566	0.629	0.627	0.599	0.654	0.029	Sí
2000	0.546	0.514	0.578	0.549	0.518	0.579	0.003	Sí
2500	0.509	0.475	0.542	0.487	0.454	0.520	-0.022	Sí
3000	0.455	0.405	0.504	0.436	0.402	0.470	-0.019	Sí

Table 5: Mediana de supervivencia: KM vs. log-normal

	Mediana (días)	IC inf. 95%	IC sup. 95%
Kaplan-Meier	2552	2152	No estimable
Log-normal	2386	2127	2677

Resultados. La curva log-normal sigue la forma global del KM; la diferencia absoluta promedio entre ambas es de 0.019. La mayor diferencia positiva (0.043) ocurre cerca del día 1331, donde el modelo sobreestima la supervivencia, y la mayor diferencia negativa (-0.047) cerca del día 3329, en la cola, donde la subestima. La log-normal queda dentro del IC 95% del KM en 81.3% del rango observado. En los tiempos clave, solo a los 1000 días su estimación (0.728) queda fuera del IC del KM (0.66, 0.719). La mediana del KM es de 2552 días, con límite inferior de 2152 y límite superior no estimable (la banda superior del KM no cruza 0.5 en el seguimiento observado); la de la log-normal es de 2386 días, ligeramente menor pero dentro del IC del KM.

Discusión. El modelo log-normal describe de manera razonable, aunque no perfecta, los datos. Reproduce el descenso global de la supervivencia y la mediana, y en casi todo el rango sus diferencias con el KM son pequeñas (menores a 0.05 en S(t)). Sin embargo, las diferencias son sistemáticas: hasta ~700 días la log-normal queda apenas por debajo del KM; entre ~700 y ~2000 días queda por encima, con máximo cerca de 1000 a 1500 días, y a los 1000 días su estimación sale del IC 95% del KM, que es la única discrepancia de ese tipo en los tiempos clave; después de ~2000 días la relación se invierte y el modelo subestima la supervivencia, porque el KM se aplana (≈ 0.45 al final) mientras la log-normal sigue descendiendo. En esa cola hay pocos pacientes en riesgo y el IC del KM es amplio, por lo que debe interpretarse con cautela. Esto es consistente con el punto 1, donde la gamma generalizada obtuvo mejor AIC y la prueba de razón de verosimilitud rechazó la log-normal al 5%. En conjunto, la log-normal es una aproximación útil, pero si el interés fuera una predicción a tiempos largos convendría un modelo más flexible, como la gamma generalizada.

4. Ajuste de un modelo de Cox.

Se ajusta un modelo de riesgos proporcionales usando todas las covariables de la base datos. Obtenemos 15 parámetros de las cuales individualmente solo 6 son significativos.

Razones de riesgo (HR). Las HR de las covariables categóricas indican que si el individuo se encuentra en uno de los siguientes grupos su riesgo aumenta o disminuye respecto al grupo base a una proporción $\exp(\beta)$.

$$\frac{h_j(t; \text{Grupo} = 1)}{h_i(t; \text{Grupo} = 0)} = e^{\beta_{\text{Grupo}}}$$

Por otro lado, si la variable es numérica (nodes) quiere decir que cada unidad adicional de nódulos linfáticos aumenta o disminuye en una proporción $\exp(\beta)$.

$$\frac{h_j(t; \text{nodes} = X + 1)}{h_i(t; \text{nodes} = X)} = e^{\beta_{\text{nodes}}}$$

Intervalos de confianza. Las razones estimadas y sus intervalos de confianza al 95% de confianza están dadas por la siguiente tabla.

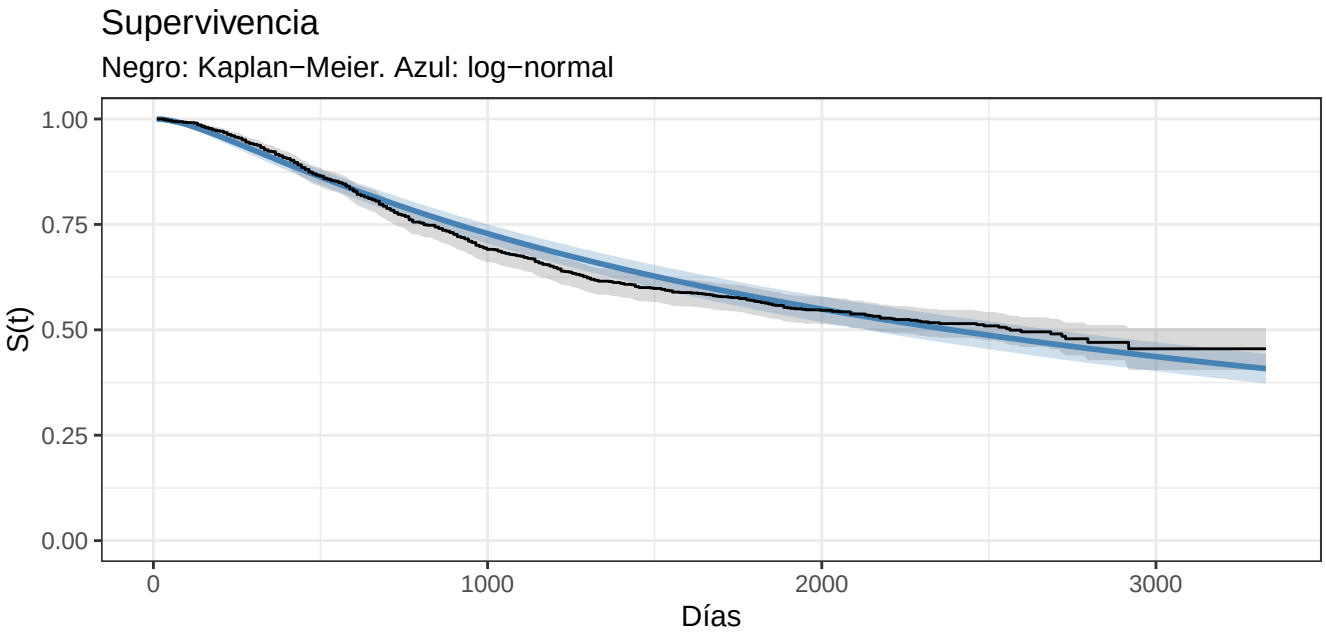


Figure 3: Kaplan–Meier (negro, banda gris) vs. log-normal (azul, banda IC 95%).

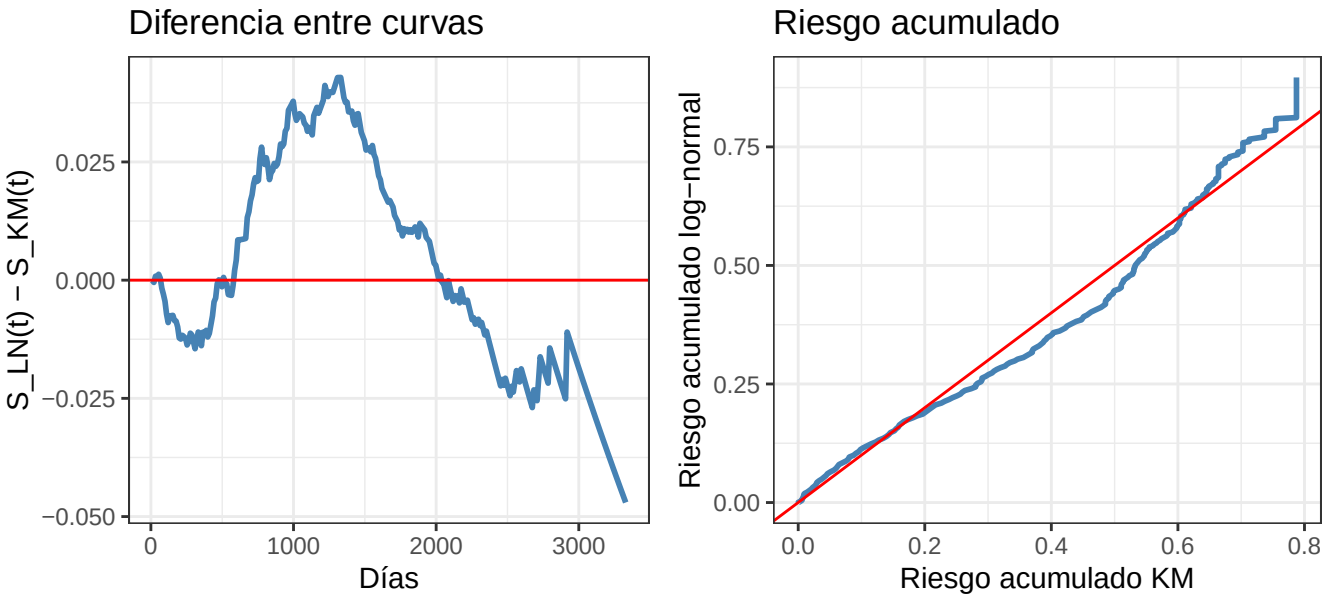


Figure 4: Izquierda: diferencia entre la log-normal y KM. Derecha: riesgo acumulado de ambos modelos (la recta roja es la identidad).

Table 6: Coeficientes, IC 95% y su efecto

	coef	Pr(>|z|)	exp(coef)	lower .95	upper .95
rxLev	-0.0556	0.6286	0.9460	0.7553	1.1848
rxLev+5FU	-0.3744	0.0022	0.6877	0.5411	0.8740
sexmale	0.0122	0.9005	1.0123	0.8358	1.2261
age	0.0076	0.0688	1.0077	0.9994	1.0160
obstruct1	0.2668	0.0272	1.3058	1.0304	1.6548
perfor1	0.0101	0.9701	1.0102	0.5950	1.7151
adhere1	0.1704	0.1998	1.1857	0.9139	1.5384
nodes	0.0438	0.0038	1.0448	1.0142	1.0763
differmoderate	-0.1132	0.5025	0.8930	0.6415	1.2431
differpoor	0.1706	0.3882	1.1860	0.8050	1.7471
extentsubmucosa	-0.9874	0.0909	0.3726	0.1186	1.1704
extentmuscle	-0.4945	0.0054	0.6099	0.4304	0.8642
extentcont.str	0.3670	0.0900	1.4434	0.9443	2.2061
surglong	0.2344	0.0277	1.2642	1.0260	1.5576
node4_1	0.6760	0.0000	1.9660	1.4868	2.5996

De los coeficientes significantes se registran los siguientes efectos (aumentos si $\exp(\beta) > 1$ y disminuciones si $\exp(\beta) < 1$) al riesgo base.

- rxLev+5FU: disminución de 31.23%.
- obstruct1: aumento de 30.58%.
- nodes: aumento de 4.48% por cada nódulo linfático adicional.
- extentmuscle: disminución de 39.01%.
- surglong: aumento de 26.42%.
- node4_1: aumento de 96.6%.

Tenemos muchos coeficientes que no son significativos y su presencia puede afectar de manera general al ajuste asi como causar el incumplimiento del supuesto de riesgos proporcionales. Sin embargo, variables como extentsubmucosa, extentcont.str y age siguen cuasando cierto efecto que vale la pena investigar. Esto es en especial notorio por los intervalos de confianza que aunque incluyen al cero mantiene un efecto contrario al estimado relativamente leve (depende de la variable).

El resto de variables aportan un efecto confuso y se debe realiza una selección de variables con cuidado.

Significancia global. Según las pruebas de Wald, Score y Log se asume la hipótesis nula de coeficientes nulos en todo el modelo, por lo que al rechazar la hipótesis se tiene que al menos una covariable es significativa para el modelo global. Los resultados de las pruebas se muestran en la siguiente tabla.

Table 7: Pruebas de significancia global

Prueba	df	p_valor
Wald	15	0
Score	15	0
Log	15	0

Son rechazadas todas las pruebas, el modelo es significativo globalmente. Se observa una concordancia de 67.51% indicando un ajuste modesto.

Selección de variables. Realizando una prueba de ZPH en el modelo con todas las covariables se verificó que solamente tres variables no cumplen el supuesto de riesgos proporcionales individualmente (obstruct, differ, node4). Estas afectan al modelo global y es mejor eliminarlas (incluso si algunas son significantes).

Otro cambio que se realizó fue en la base directamente al unir rxLev y rxObs con el objetivo de refinar el modelo ligeramente. Esta decisión surgió ya que al grupo al que se le aplicó levamisol (un fármaco utilizado contra gusanos parásitos) no es significante contra el riesgo base (grupo de observación). Usando el criterio AIC y BIC comparamos ambos modelos originales y obtuvimos un mejor modelo utilizando la base de datos refinada.

Se usó la función stepAIC hacia atrás desde el modelo con las covariables obstruct, differ y node4 eliminadas (variables que no cumplen riesgos proporcionales) y el mejor modelo fue usando solamente rx, adhere, nodes, extent y surg (AIC:). Los coeficientes se muestran en la siguiente tabla

Table 8: Coeficientes, IC 95% y su efecto

	coef	Pr(>|z|)	exp(coef)	lower .95	upper .95
rxLev+5FU	-0.3277	0.0026	0.7206	0.5821	0.8919
adhere1	0.2407	0.0640	1.2721	0.9861	1.6411
nodes	0.2835	0.0000	1.3278	1.1894	1.4822
I(nodesˆ2)	-0.0149	0.0090	0.9852	0.9743	0.9963
I(nodesˆ3)	0.0002	0.0749	1.0002	1.0000	1.0005
extentsubmucosa	-1.0659	0.0670	0.3444	0.1101	1.0776
extentmuscle	-0.4604	0.0096	0.6311	0.4455	0.8939
extentcont.str	0.3930	0.0675	1.4814	0.9721	2.2576
surglong	0.2424	0.0223	1.2743	1.0351	1.5687

De los coeficientes significantes se registran los siguientes efectos al riesgo base.

- rxLev+5FU: disminución de 27.94%.
- extentmuscle: disminución de 36.89%.
- surglong: aumento de 28.58%.

En el caso de nodes en el que tenemos un polinomio de grado 3. Ocurrirá que la razón de riesgo por cada nódulo adicional dependerá de la misma variable. Es decir

$$\frac{h_j(t; \text{nodes} = X + 1)}{h_i(t; \text{nodes} = X)} = \exp(\beta_3 + \beta_4(2X + 1) + \beta_5(3X^2 + 3X + 1))$$

En general, el polinomio cúbico nos ayuda a controlar valores extremos en los nódulos (se tiene un máximo de 33 nódulos) ya que el 79.4% de los datos tiene no mas de 5 nódulos. Esto es notorio debido al valor negativo pequeño en el término cuadrado y un valor muy cercano a cero en el término cúbico (no es significante como tal pero su efecto no es menor a 1).

De los coeficientes no significantes se tienen los siguientes efectos al riesgo base. Los intervalos de confianza indican que es posible que se vea un efecto opuesto al estimado, esto debido a posible falta de observaciones de estas categorías.

- adhere1: aumento de 27.21% (37 observaciones del total de 888).
- extentsubmucosa: disminución de 65.56% (19 observaciones del total de 888).
- extentcont.str: aumento de 48.14% (128 observaciones del total de 888)

La significancia global indica una concordancia de 66.5% indicando un ajuste modesto.

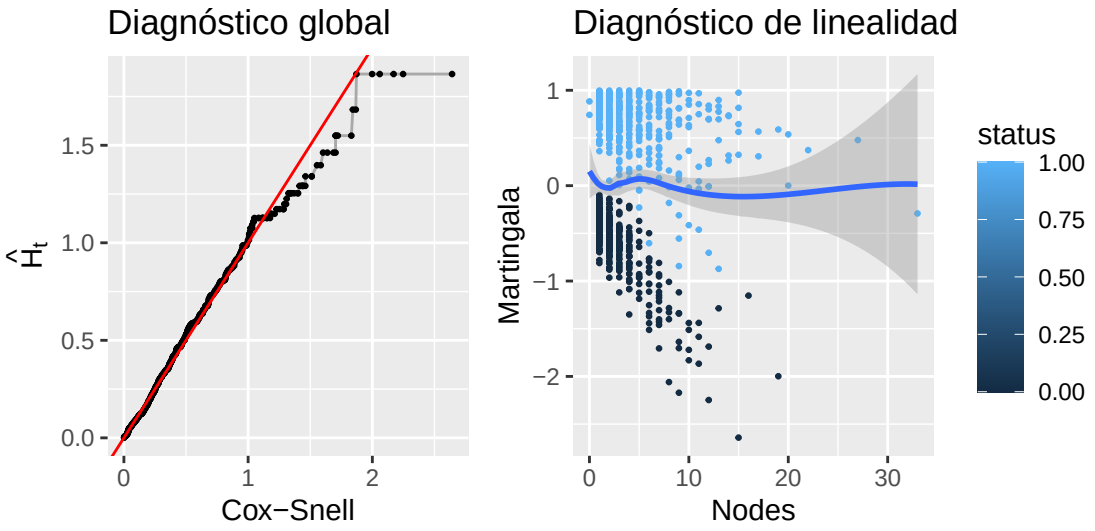
Table 9: Pruebas de significancia global

Prueba	df	p_valor
Wald	9	0
Score	9	0

Prueba	df	p_valor
Log	9	0

Son rechazadas todas. El modelo es significante globalmente. Ahora se realiza análisis residual.

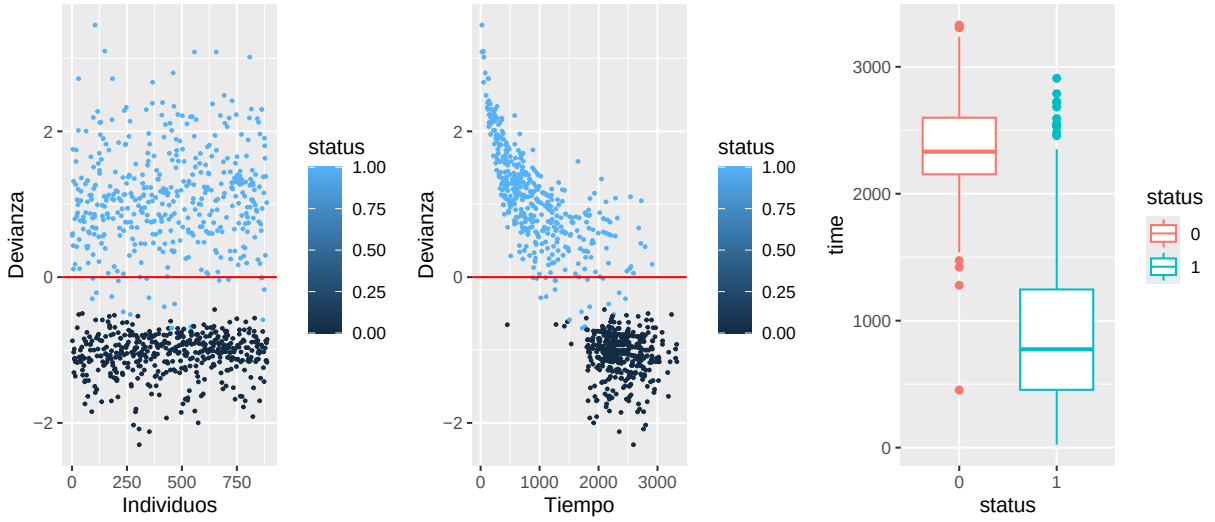
Cox-Snell y Martingala. Se extraen los residuos martingala utilizados para calcular los residuos Cox-Snell. La primera gráfica utiliza el ajuste de supervivencia por Kaplan-Meier tomando los residuos Cox-Snell como los tiempos. Se grafica el riesgo acumulado vs. el tiempo y se verifica si los puntos se ajustan a la recta. La segunda grafica los residuos martingala vs. nódulos. Se usa para verificar la linealidad de la variable numérica (Durante el proceso de selección de variables se visualizaba una curva cúbica en esta gráfica, por lo que se consideró necesario usar un polinomio cúbico).



En la primera gráfica parece que los puntos se ajustan bien a la recta al inicio, comforme nos acercamos a los últimos puntos, estos empiezan a desviarse de la recta fuertemente. Esto señala falta de ajuste ante valores altos, pero la cola suele tener pocos pacientes y muchas censuras. Asi que por si sola no basta para concluir un modelo mal ajustado.

La segunda gráfica nos muestra que el polinomio cúbico mantiene la recta loess aproximadamente constante y cerca de cero. No es necesaria una tranformación adicional a esta variable.

Devianza. Se usa para medir posibles valores atípicos. Se hace extrayendo los residuales de devianza y graficarlos contra los individuos (id) y contra el tiempo. Valores altos de devianza en algún individuo que este puede ser un outlier. Las gráficas se ven de la siguiente manera



Vemos que todas las censuras tienen devianza negativa y la mayoría de las muertes tiene devianza positiva. Para este modelo se puede apreciar que los individuos que murieron en los primeros dias del estudio tienen una mayor devianza. Vale la pena estudiar el comportamiento.

Una fuerte sospecha sobre este comportamiento es debido a la naturaleza directa con las censuras mismas. Se incluye un diagrama boxplot que indica la distribución del tiempo para muertes y censuras en el cual se observa que el 82.6% de las muertes ocurren antes de 1500 días mientras que el 99.1% de las censuras ocurren despues de 1500 días. Esta disparidad podría generar este tipo de problemas.

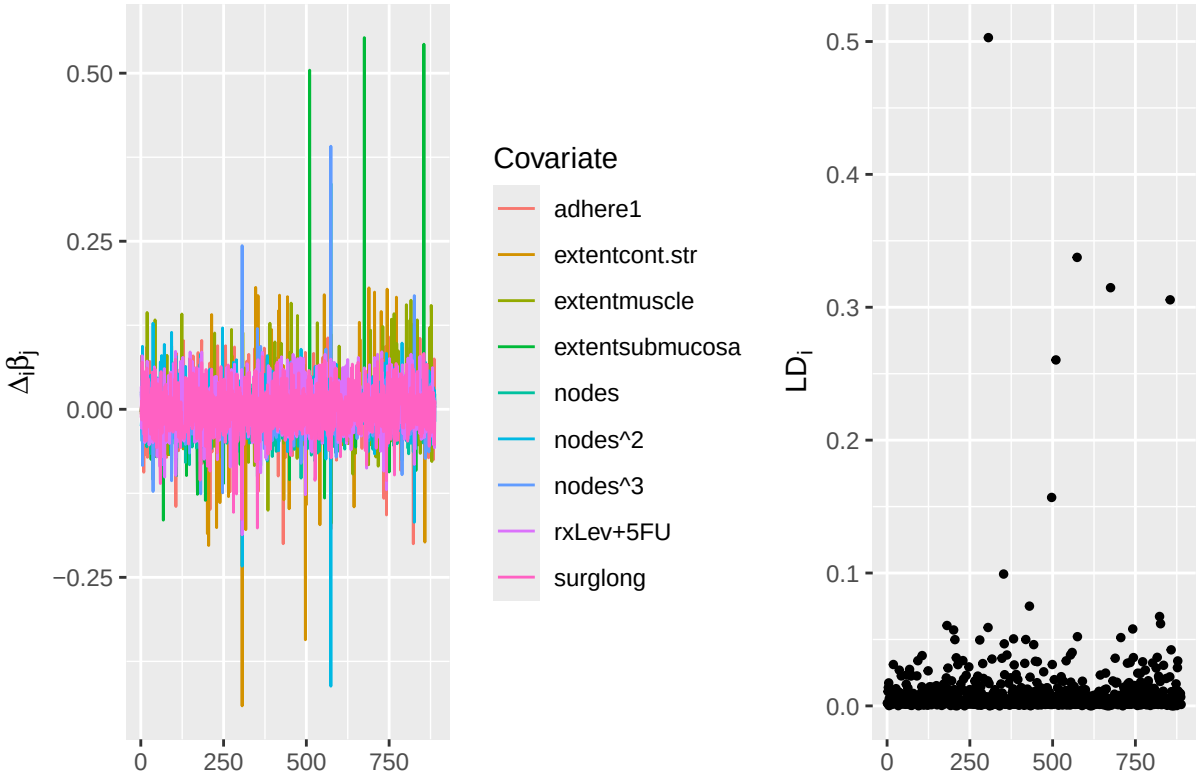
Esto hace que las observaciones con devianzas fuertes sean los individuos que murieron al inicio del estudio lo cual nos dificulta interpretar si en realidad son outliers o resultado de la naturaleza de los datos en cuestion de la censura.

Table 10: Individuos con devianza alta

	id	time	status	rx	adhere	nodes	extent	surg
59	30	133	1	Obs/Lev	0	1	serosa	short
219	105	23	1	Lev+5FU	0	3	serosa	long
309	149	45	1	Lev+5FU	0	2	serosa	long
385	184	127	1	Lev+5FU	1	1	serosa	long
775	367	52	1	Lev+5FU	0	9	serosa	long
963	460	79	1	Lev+5FU	0	5	serosa	short
1167	557	34	1	Lev+5FU	0	5	serosa	short
1377	656	24	1	Obs/Lev	0	4	serosa	long
1697	809	56	1	Obs/Lev	0	1	serosa	short

Todos los individuos tienen tiempos de muerte pequeños como se esperaba que ocurriera en la gráfica (la mediana del tiempo de muerte es de 774.5). También es notable el hecho de que todos pertenecen a extend_serosa (grupo base en extend).

Delta-betas y desplazamiento de la verosimilitud. Estos residuales se usan para verificar valores influyentes en el modelo. Las delta-betas se usan para verificar que pacientes afectan fuertemente a la estimación del coeficiente de alguna covariable en especifico. El desplazamiento de la verosimilitud describe que pacientes afectan fuertemente al modelo en general.



Riesgos proporcionales.

```
##                chisq df     p
## rx            0.6928  1 0.405
## adhere        0.0668  1 0.796
## nodes         1.4169  1 0.234
## I(nodes^2)    0.0587  1 0.808
## I(nodes^3)    1.7422  1 0.187
## extent        6.5594  3 0.087
## surg          0.0039  1 0.950
## GLOBAL       16.3705  9 0.060
```