Proyecto Supervivencia

Nicolás de Silva Nacenta

2026-10-18

0. Análisis descriptivo

1. Modelo paramétrico para el tiempo de supervivencia

Ajustamos a los 929 pacientes, sin covariables, seis distribuciones: exponencial, Weibull, log-normal, log-logística, Gompertz y gamma generalizada (que contiene a varias de las anteriores como casos particulares).

Table 1: Comparación de distribuciones (dAIC y dBIC: diferencia contra la mejor)

Distribución	Parámetros	AIC	BIC	dAIC	dBIC
Exponencial	1	8265.4	8270.3	52.5	43.5
Weibull	2	8267.4	8277.1	54.5	50.3
Log-normal	2	8217.1	8226.8	4.2	0.0
Log-logística	2	8236.8	8246.4	23.9	19.6
Gompertz	2	8251.2	8260.8	38.2	34.0
Gamma generalizada	3	8212.9	8227.4	0.0	0.6

Elección de la distribución. Comparamos con AIC y BIC (menor es mejor; el BIC penaliza más los parámetros extra). El AIC favorece moderadamente a la gamma generalizada (la log-normal queda a 4.2 puntos), mientras que el BIC las considera casi equivalentes (diferencia de 0.6, a favor de la log-normal). Las demás distribuciones quedan a más de 20 puntos de AIC.

La Weibull estima una forma de 1, es decir, se reduce a la exponencial (riesgo constante); las distribuciones que permiten que el riesgo crezca y luego baje (log-normal, gamma generalizada, log-logística) ajustan mejor que las que no. La prueba de razón de verosimilitud contra la gamma generalizada rechaza la log-normal al 5% ($p = 0.013$), aunque no al 1%, y la mejora es modesta. Elegimos la log-normal por ser más simple y porque su versión con covariables (punto 4) se interpreta de forma directa. Reconocemos que ningún modelo paramétrico reproduce exactamente a Kaplan-Meier.

Elección de la distribución. Utilizamos criterios de información AIC y BIC, acompañados de las características del riesgo y de la prueba de verosimilitud.

En términos de AIC, el modelo ganador es la gamma generalizada, quedándose cerca la distribución log-normal (4.2 puntos), por otro lado, en términos de BIC (el cual penaliza más los parámetros extra), se favorece a la distribución log-normal, considerando casi equivalente a la distribución gamma generalizada (diferencia de 0.6, a favor de la log-normal). El resto de distribuciones se aleja por varios puntos. Así, en términos de AIC y BIC las distribuciones favoritas son log-normal y gamma generalizada.

Al analizar las características del riesgo, notamos que la Weibull estima un parámetro de forma de 1, es decir, se reduce a la exponencial (riesgo constante); sin embargo, las distribuciones que permiten que el riesgo crezca y luego baje (log-normal, gamma generalizada, log-logística) ajustan mejor que las que no.

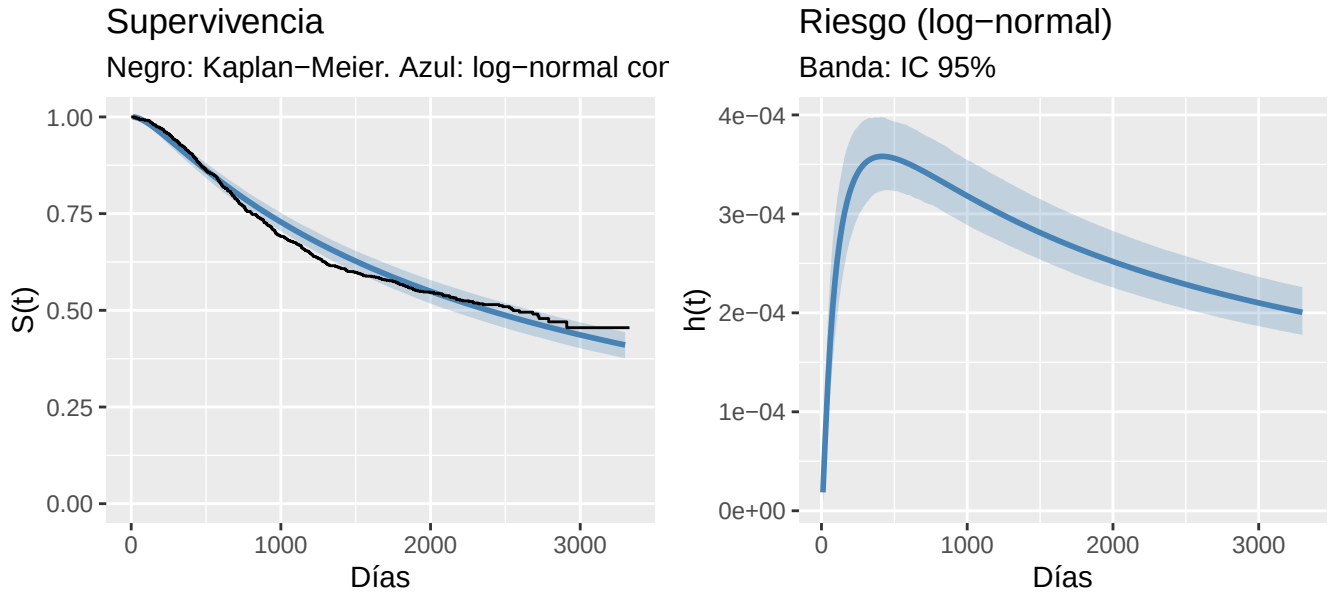
La prueba de razón de verosimilitud contra la gamma generalizada rechaza la log-normal al 5% ($p = 0.013$), aunque no al 1%, sin embargo, la mejoría es modesta. Por lo tanto, elegimos la distribución log-normal

por explicar bien el riesgo, ajustar adecuadamente a los datos y ser más simple, así mismo, su versión con covariables se interpreta de forma directa.

Finalmente, es importante reconocer que ningún modelo paramétrico termina por reproducir exactamente la estimación con Kaplan Meier.

Table 2: Log-normal: estimadores de máxima verosimilitud y mediana

	Estimador	IC inf. 95%	IC sup. 95%
meanlog	7.78	7.66	7.89
sdlog	1.43	1.33	1.54
Mediana (días)	2385.94	2126.69	2676.80



4. Ajuste de un modelo de Cox.

Table 3: Coeficientes del modelo con todas las covariables

	coef	exp(coef)	se(coef)	z	Pr(>|z|)
rxLev	-0.0556	0.9460	0.1148	-0.4837	0.6286
rxLev+5FU	-0.3744	0.6877	0.1223	-3.0611	0.0022
sexmale	0.0122	1.0123	0.0978	0.1250	0.9005
age	0.0076	1.0077	0.0042	1.8198	0.0688
obstruct1	0.2668	1.3058	0.1208	2.2081	0.0272
perfor1	0.0101	1.0102	0.2701	0.0375	0.9701
adhere1	0.1704	1.1857	0.1329	1.2822	0.1998
nodes	0.0438	1.0448	0.0152	2.8908	0.0038
differmoderate	-0.1132	0.8930	0.1688	-0.6706	0.5025
differpoor	0.1706	1.1860	0.1977	0.8628	0.3882
extentmuscle	0.4928	1.6369	0.6051	0.8145	0.4154
extentserosa	0.9874	2.6841	0.5840	1.6906	0.0909
extentcontiguous structures	1.3543	3.8742	0.6193	2.1868	0.0288

	coef	exp(coef)	se(coef)	z	Pr(>|z|)
surglong	0.2344	1.2642	0.1065	2.2012	0.0277
node41	0.6760	1.9660	0.1425	4.7427	0.0000

```
## Call:
## coxph(formula = Surv(time, status == 1) ~ rx + adhere + nodes +
##     surg, data = data_ref)
##
##   n= 888, number of events= 430
##
##                coef exp(coef)  se(coef)      z Pr(>|z|)
## rxLev+5FU -0.317395  0.728043  0.108814 -2.917  0.00354 **
## adhere1    0.283372  1.327599  0.127857  2.216  0.02667 *
## nodes      0.092342  1.096739  0.009036 10.219  < 2e-16 ***
## surglong   0.252156  1.286797  0.105956  2.380  0.01732 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##           exp(coef) exp(-coef) lower .95 upper .95
## rxLev+5FU     0.728     1.3735    0.5882    0.9011
## adhere1       1.328     0.7532    1.0333    1.7057
## nodes         1.097     0.9118    1.0775    1.1163
## surglong      1.287     0.7771    1.0455    1.5838
##
## Concordance= 0.645  (se = 0.013 )
## Likelihood ratio test= 90.78  on 4 df,   p=<2e-16
## Wald test            = 123.4  on 4 df,   p=<2e-16
## Score (logrank) test = 125.4  on 4 df,   p=<2e-16
```

Análisis residual

“‘{r}eval=FALSE}

Cox - Snell

res_mart = residuals(mod,type=‘martingale’) res_cs = (data_ref$status == 1) - $res_martdata_ref$res_cs = res_cs

KM using the Cox-Snell residuals as the times

fit_cs = survfit(Surv(res_cs, status == 1) ~ 1, data = data_ref)

Plot cumulative hazard

df = data.frame(x=fit_cs$time, $y = -log(fit_c$ssurv))

ggplot(data=df,aes(x=x,y=y))+ geom_line(col=‘darkgrey’)+ geom_point(size=.5)+ labs(x=“Cox-Snell residuals”,y=expression(hat(H[t])))+ geom_abline(intercept=0,slope=1,col=“red”)

Martingala

Martingale residuals vs continuous variables

data_ref$res_mart = res_mart

ggplot(data=data_ref,aes(x=nodes,y=res_mart))+ geom_point()+ geom_smooth(method = “loess”, se = T, span = 0.75)+ labs(x=‘Nodes’,y=‘Martingale residuals’)

Devianza

res_dev = residuals(mod,type=‘deviance’) data_ref$res_dev = res_dev

ggplot(data=data_ref,aes(x=id,y=res_dev))+ geom_point()+ geom_hline(yintercept=0,col=‘red’)+ labs(x=“ “,y=”Deviance residuals”)

Delta-betas

res_dbs = residuals(mod, type = “dfbetas”) res_db = residuals(mod, type = “dfbeta”)

number of observations (n) and covariates (k)

n = nrow(data_ref) k = 5 id = rep(1:n, k)

vars = c(rep(‘rxLev+5FU’,n),rep(‘adhere1’,n),rep(‘nodes’,n), rep(‘nodes^2’,n),rep(‘surglong’,n))

val_std = c(res_dbs[,1],res_dbs[,2],res_dbs[,3], res_dbs[,4], res_dbs[,5])

val = c(res_db[,1],res_db[,2],res_db[,3], res_db[,4], res_db[,5])

db_df=data.frame(x=id,y_std=val_std,y=val,name=vars)

ggplot(data=db_df,aes(x=x,y=y_std,col=name))+ geom_line()+ labs(x=’’,y=expression(Delta[i]*beta[j]), color = “Covariate”)

Likelihood displacement

LD = numeric(n) res_u = residuals(mod,type=‘score’) var_beta = mod$var

for(i in 1:n){ LD[i]=t(res_u[i,])%*%var_beta%*%res_u[i,] }

id = c(1:n) LD_df = data.frame(x=id,y=LD)

ggplot(data=LD_df,aes(x=id,y=y))+ geom_point()+ labs(x=“ “,y=expression(LD[i]))

View(LD_df %>% filter(y>.05))

cox.zph(mod)

View(db_df %>% filter(abs(y_std)>.15)) “‘

5. Ajuste de una regresión paramétrica.