Proyecto Supervivencia

Nicolás de Silva Nacenta

2026-10-18

0. Análisis descriptivo

1. Modelo paramétrico para el tiempo de supervivencia

Ajustamos a los 929 pacientes, sin covariables, seis distribuciones: exponencial, Weibull, log-normal, log-logística, Gompertz y gamma generalizada (que contiene a varias de las anteriores como casos particulares).

Table 1: Comparación de distribuciones (dAIC y dBIC: diferencia contra la mejor)

Distribución	Parámetros	AIC	BIC	dAIC	dBIC
Exponencial	1	7869.8	7874.6	47.9	39.8
Weibull	2	7871.8	7881.4	49.9	46.6
Log-normal	2	7825.2	7834.8	3.3	0.0
Log-logística	2	7843.4	7853.0	21.6	18.2
Gompertz	2	7856.3	7865.9	34.4	31.1
Gamma generalizada	3	7821.9	7836.2	0.0	1.4

Elección de la distribución. Comparamos con AIC y BIC (menor es mejor; el BIC penaliza más los parámetros extra). El AIC favorece moderadamente a la gamma generalizada (la log-normal queda a 3.3 puntos), mientras que el BIC las considera casi equivalentes (diferencia de 1.4, a favor de la log-normal). Las demás distribuciones quedan a más de 20 puntos de AIC.

La Weibull estima una forma de 1, es decir, se reduce a la exponencial (riesgo constante); las distribuciones que permiten que el riesgo crezca y luego baje (log-normal, gamma generalizada, log-logística) ajustan mejor que las que no. La prueba de razón de verosimilitud contra la gamma generalizada rechaza la log-normal al 5% ($p = 0.021$), aunque no al 1%, y la mejora es modesta. Elegimos la log-normal por ser más simple y porque su versión con covariables (punto 4) se interpreta de forma directa. Reconocemos que ningún modelo paramétrico reproduce exactamente a Kaplan-Meier.

Elección de la distribución. Utilizamos criterios de información AIC y BIC, acompañados de las características del riesgo y de la prueba de verosimilitud.

En términos de AIC, el modelo ganador es la gamma generalizada, quedándose cerca la distribución log-normal (3.3 puntos), por otro lado, en términos de BIC (el cual penaliza más los parámetros extra), se favorece a la distribución log-normal, considerando casi equivalente a la distribución gamma generalizada (diferencia de 1.4, a favor de la log-normal). El resto de distribuciones se aleja por varios puntos. Así, en términos de AIC y BIC las distribuciones favoritas son log-normal y gamma generalizada.

Al analizar las características del riesgo, notamos que la Weibull estima un parámetro de forma de 1, es decir, se reduce a la exponencial (riesgo constante); sin embargo, las distribuciones que permiten que el riesgo crezca y luego baje (log-normal, gamma generalizada, log-logística) ajustan mejor que las que no.

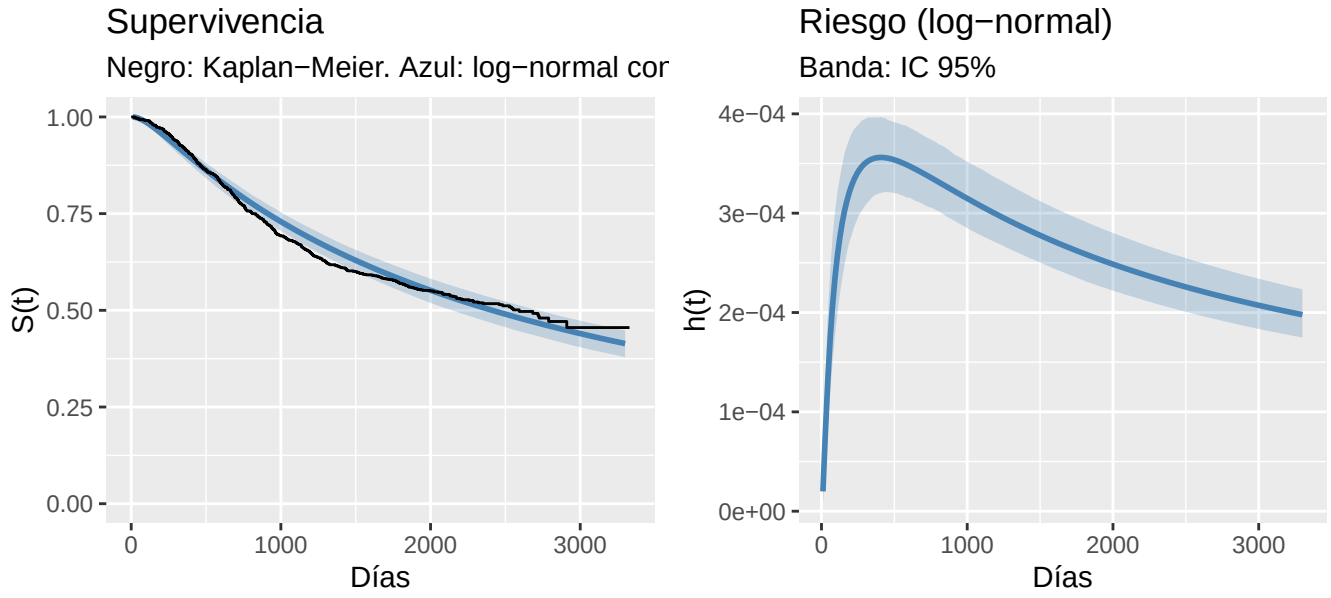
La prueba de razón de verosimilitud contra la gamma generalizada rechaza la log-normal al 5% ($p = 0.021$), aunque no al 1%, sin embargo, la mejoría es modesta. Por lo tanto, elegimos la distribución log-normal

por explicar bien el riesgo, ajustar adecuadamente a los datos y ser más simple, así mismo, su versión con covariables se interpreta de forma directa.

Finalmente, es importante reconocer que ningún modelo paramétrico termina por reproducir exactamente la estimación con Kaplan Meier.

Table 2: Log-normal: estimadores de máxima verosimilitud y mediana

	Estimador	IC inf. 95%	IC sup. 95%
meanlog	7.79	7.67	7.91
sdlog	1.44	1.34	1.55
Mediana (días)	2412.16	2141.95	2716.47



4. Ajuste de un modelo de Cox. Se ajusta un modelo de riesgos proporcionales usando todas las covariables de la base datos. Obtenemos 15 parámetros de las cuales individualmente solo 6 son significativos.

Razones de riesgo (HR). Las HR de las covariables categóricas indican que si el individuo se encuentra en uno de los siguientes grupos su riesgo aumenta o disminuye respecto al grupo base a una proporción $\exp(\beta)$.

$$\frac{h_j(t; \text{Grupo} = 1)}{h_i(t; \text{Grupo} = 0)} = e^{\beta_{\text{Grupo}}}$$

Por otro lado, si la variable es numérica (nodes) quiere decir que cada unidad adicional de nódulos linfáticos aumenta o disminuye en una proporción $\exp(\beta)$.

$$\frac{h_j(t; \text{nodes} = X + 1)}{h_i(t; \text{nodes} = X)} = e^{\beta_{\text{nodes}}}$$

Intervalos de confianza. Las razones estimadas y sus intervalos de confianza al 95% de confianza están dadas por la siguiente tabla.

Table 3: Coeficientes, IC 95% y su efecto

	coef	Pr(>|z|)	exp(coef)	lower .95	upper .95
rxLev	-0.0556	0.6286	0.9460	0.7553	1.1848
rxLev+5FU	-0.3744	0.0022	0.6877	0.5411	0.8740
sexmale	0.0122	0.9005	1.0123	0.8358	1.2261
age	0.0076	0.0688	1.0077	0.9994	1.0160
obstruct1	0.2668	0.0272	1.3058	1.0304	1.6548
perfor1	0.0101	0.9701	1.0102	0.5950	1.7151
adhere1	0.1704	0.1998	1.1857	0.9139	1.5384
nodes	0.0438	0.0038	1.0448	1.0142	1.0763
differmoderate	-0.1132	0.5025	0.8930	0.6415	1.2431
differpoor	0.1706	0.3882	1.1860	0.8050	1.7471
extentsubmucosa	-0.9874	0.0909	0.3726	0.1186	1.1704
extentmuscle	-0.4945	0.0054	0.6099	0.4304	0.8642
extentcont.str	0.3670	0.0900	1.4434	0.9443	2.2061
surglong	0.2344	0.0277	1.2642	1.0260	1.5576
node4_1	0.6760	0.0000	1.9660	1.4868	2.5996

De los coeficientes significantes se registran los siguientes efectos (aumentos si $\exp(\beta) > 1$ y disminuciones si $\exp(\beta) < 1$) al riesgo base.

- rxLev+5FU: disminución de 31.23%.
- obstruct1: aumento de 30.58%.
- nodes: aumento de 4.48% por cada nódulo linfático adicional.
- extentmuscle: disminución de 39.01%.
- surglong: aumento de 26.42%.
- node4_1: aumento de 96.6%.

Tenemos muchos coeficientes que no son significativos y su presencia puede afectar de manera general al ajuste asi como causar el incumplimiento del supuesto de riesgos proporcionales. Sin embargo, variables como extentsubmucosa, extentcont.str y age siguen cuasando cierto efecto que vale la pena investigar. Esto es en especial notorio por los intervalos de confianza que aunque incluyen al cero mantiene un efecto contrario al estimado relativamente leve (depende de la variable).

El resto de variables aportan un efecto confuso y se debe realiza una selección de variables con cuidado.

Significancia global. Según las pruebas de Wald, Score y Log-rank se asume la hipótesis nula de coeficientes nulos en todo el modelo, por lo que al rechazar la hipótesis se tiene que al menos una covariable es significativa para el modelo global. Los resultados de las pruebas se muestran en la siguiente tabla.

Table 4: Pruebas de significancia global

Prueba	df	p_valor
Wald	15	0
Score	15	0
Log	15	0

Son rechazadas todas las pruebas, el modelo es significativo globalmente. Se observa una concordancia de 67.51% indicando un ajuste modesto.

Selección de variables. Realizando una prueba de ZPH en el modelo con todas las covariables se verificó que solamente tres variables no cumplen el supuesto de riesgos proporcionales individualmente (obstruct, differ, node4). Estas afectan al modelo global y es mejor eliminarlas (incluso si algunas son significantes).

Otro cambio que se realizó fue en la base directamente al unir rxLev y rxObs con el objetivo de refinar el modelo ligeramente. Esta decisión surgió ya que al grupo al que se le aplicó levamisol (un fármaco utilizado contra gusanos parásitos) no es significante contra el riesgo base (grupo de observación). Usando el criterio AIC y BIC comparamos ambos modelos originales y obtuvimos un mejor modelo utilizando la base de datos refinada.

Se usó la función stepAIC hacia atrás desde el modelo con las covariables obstruct, differ y node4 eliminadas (variables que no cumplen riesgos proporcionales) y el mejor modelo fue usando solamente rx, adhere, nodes, extent y surg. Los resultados se muestran en la siguiente tabla

Table 5: Coeficientes, IC 95% y su efecto

	coef	Pr(>|z|)	exp(coef)	lower .95	upper .95
rxLev+5FU	-0.3203	0.0032	0.7259	0.5866	0.8984
adhere1	0.2216	0.0880	1.2481	0.9676	1.6100
nodes	0.0896	0.0000	1.0938	1.0742	1.1137
extentsubmucosa	-1.1753	0.0432	0.3087	0.0988	0.9645
extentmuscle	-0.5226	0.0032	0.5930	0.4191	0.8390
extentcont.str	0.3690	0.0856	1.4463	0.9496	2.2028
surglong	0.2514	0.0179	1.2858	1.0443	1.5832

De los coeficientes significantes se registran los siguientes efectos al riesgo base.

- rxLev+5FU: disminución de 27.41% (disminución porcentual de 3.82% respecto al modelo y base de datos original).
- nodes: aumento de 9.38% por cada nódulo linfático adicional (aumento porcentual de 4.9% respecto al modelo original).
- extentsubmucosa: disminución de 69.13%.
- extentmuscle: disminución de 40.7% (aumento porcentual de 1.69% respecto al modelo original).
- surglong: aumento de 28.58% (aumento porcentual de 2.16% respecto al modelo original).

De los coeficientes no significantes se tienen los siguientes efectos al riesgo base. Los intervalos de confianza indican que es posible que se vea un efecto opuesto al estimado, esto debido a posible falta de observaciones de estas categorias.

- adhere1: aumento de 24.81% (37 observaciones del total de 888).
- extentcont.str: aumento de 44.63% (128 observaciones del total de 888)

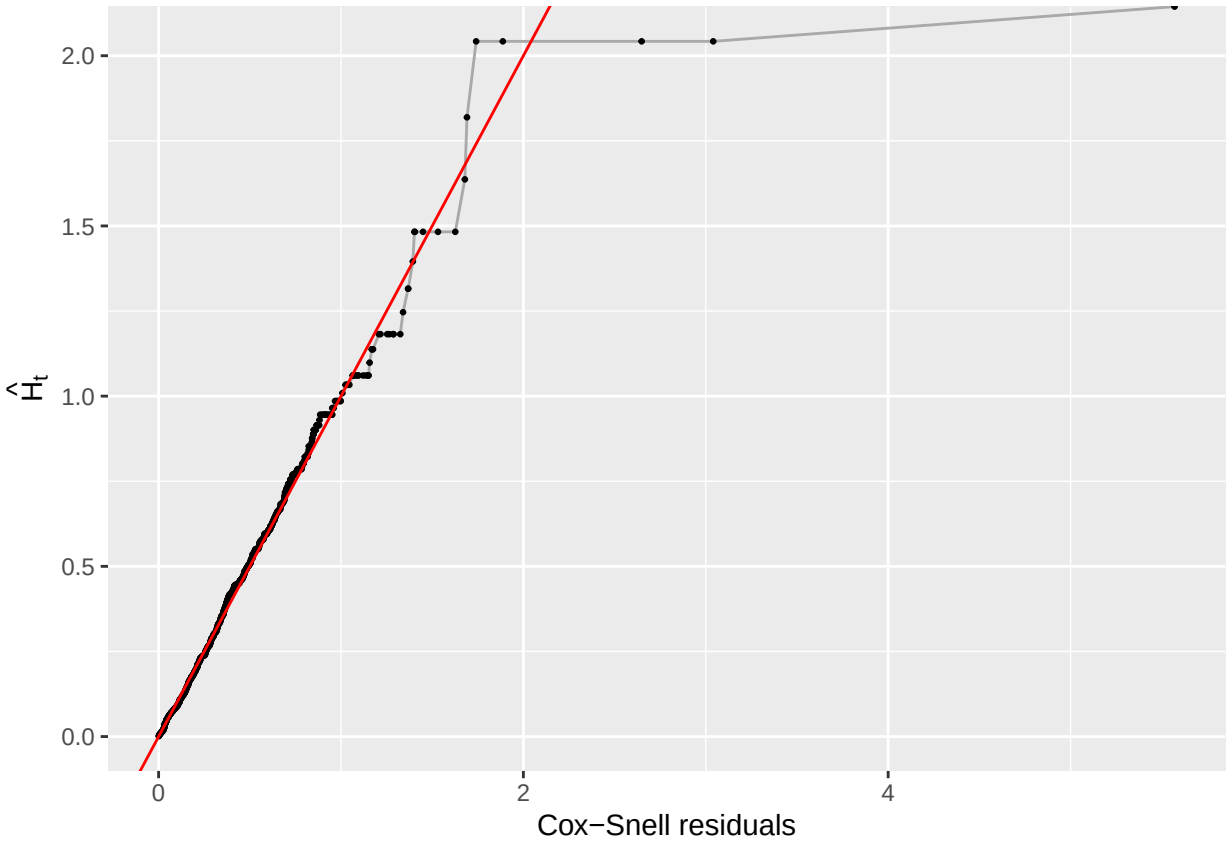
La significancia global indica una concordancia de 65.72% (disminución porcentual de 1.79% respecto al modelo original) indicando un ajuste modesto.

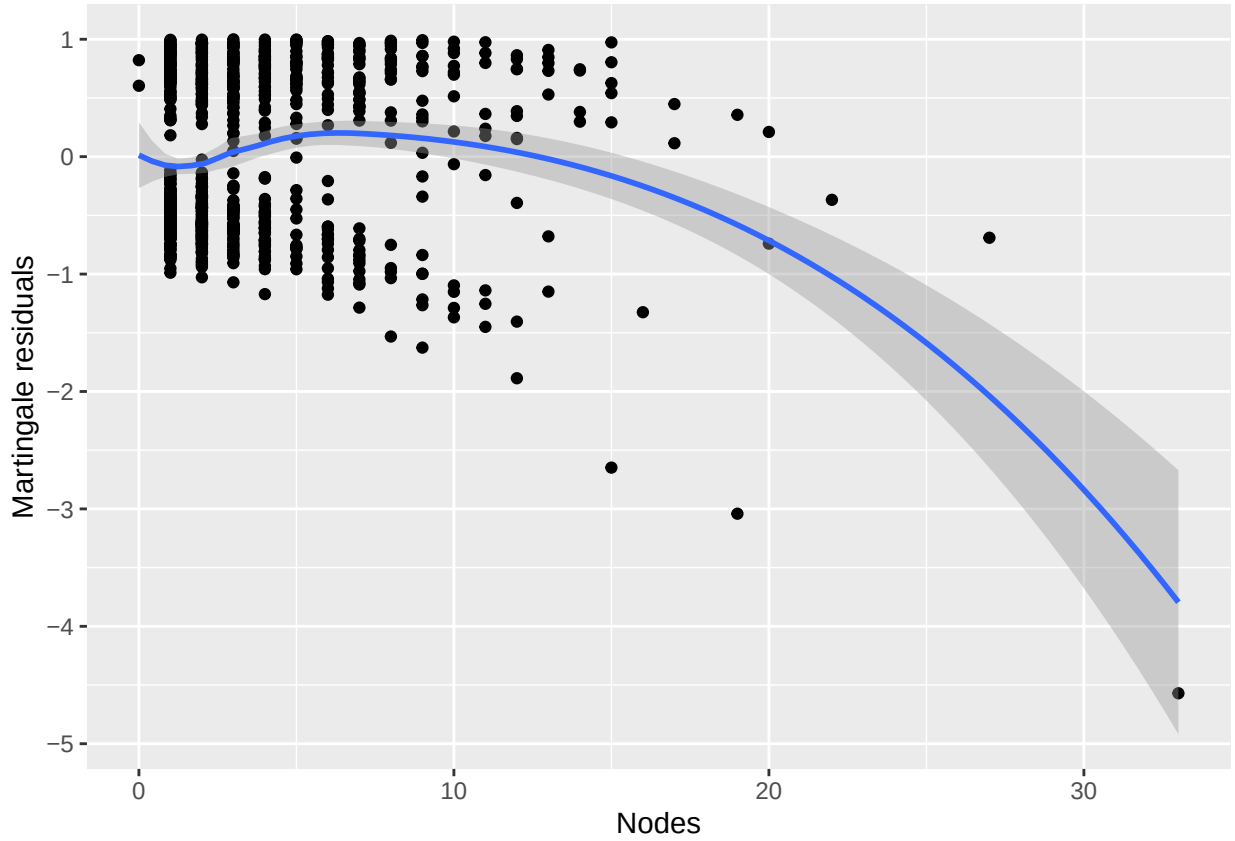
Table 6: Pruebas de significancia global

Prueba	df	p_valor
Wald	7	0
Score	7	0
Log	7	0

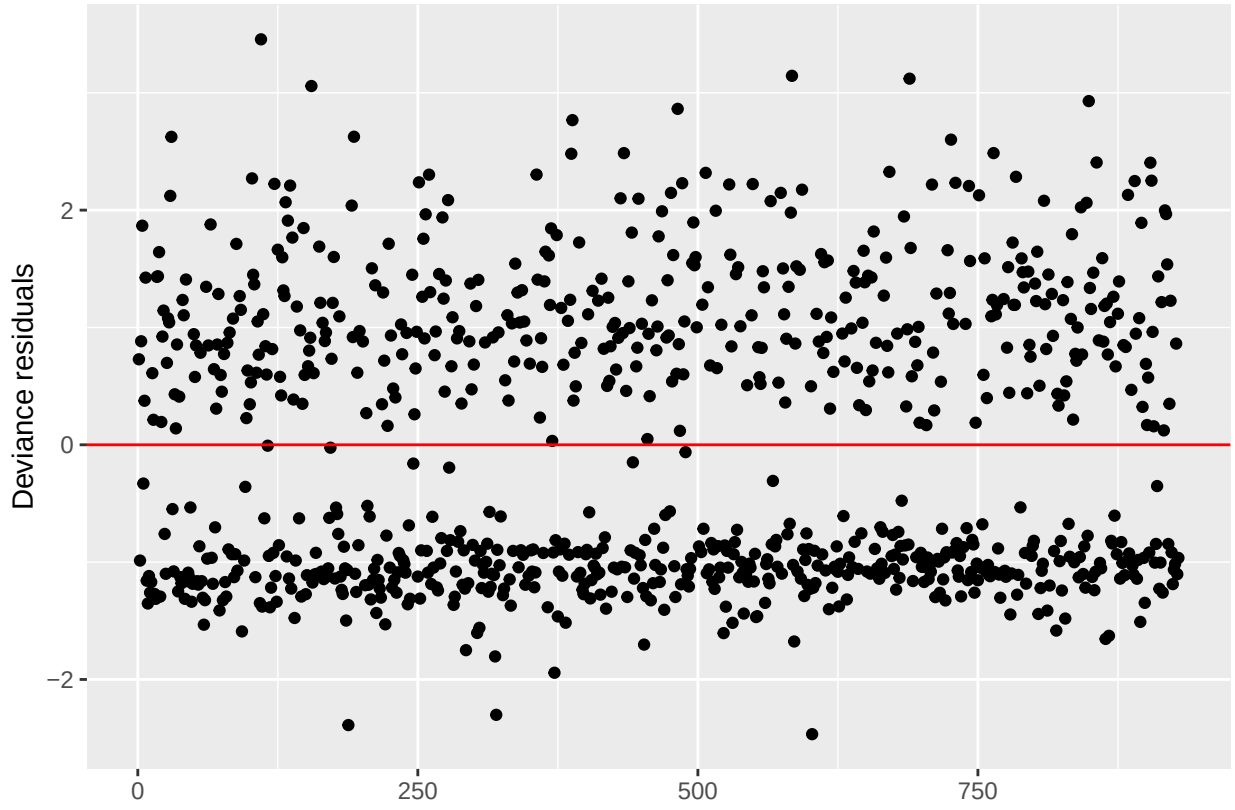
Son rechazadas todas. El modelo es significante globalmente. Ahora se realiza análisis residual.

Cox-Snell y Martingala.

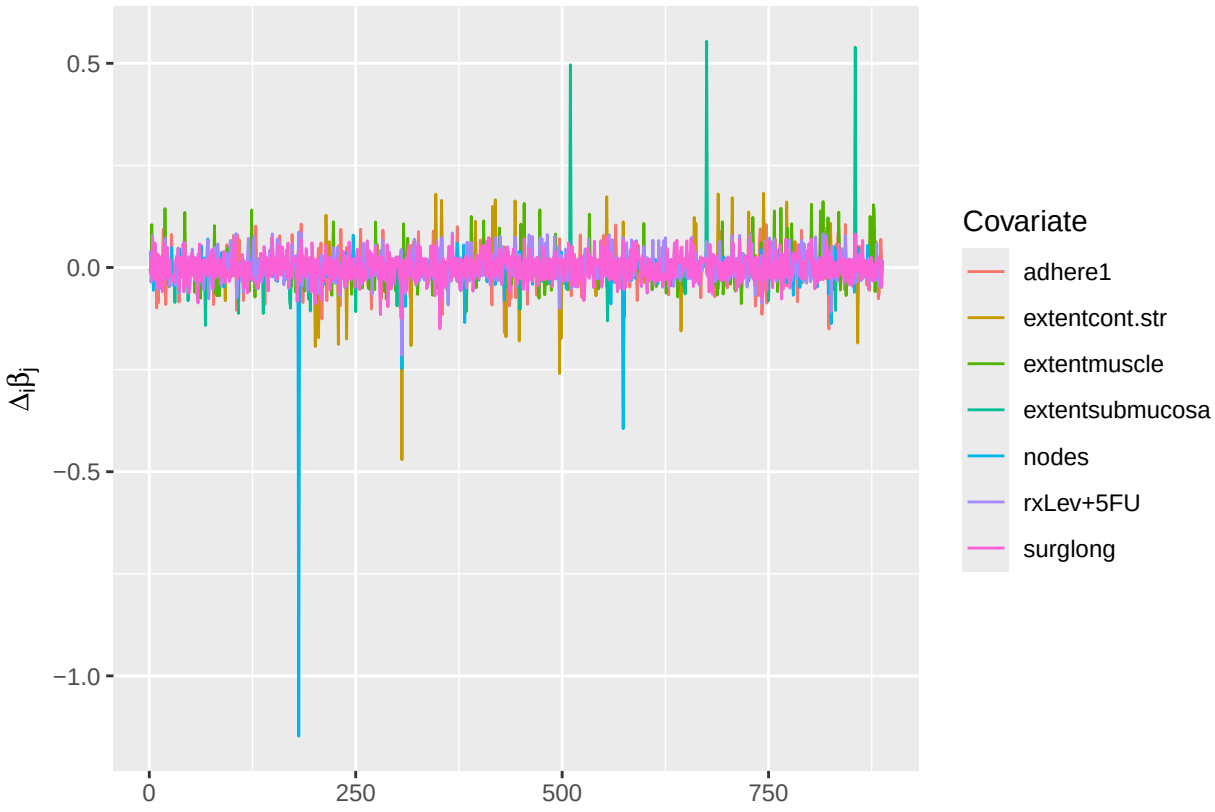

2.0
1.5
1.0
0.5
0.0
$\hat{H}_t$
0
2
4
Cox−Snell residuals

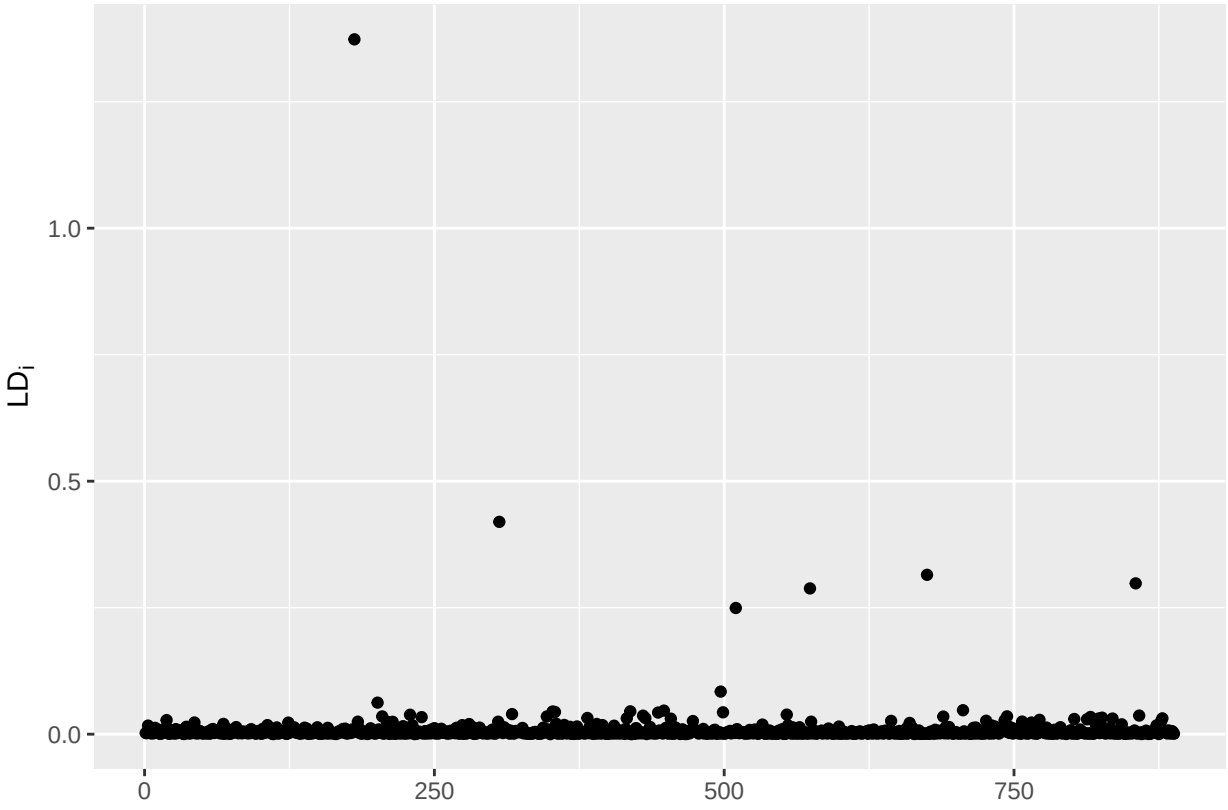


Devianza.



Delta-betas y desplazamiento de la verosimilitud.


0.5
0.0
−0.5
−1.0
$\Delta_i\beta_j$
0
250
500
750
Covariate
adhere1
extentcont.str
extentmuscle
extentsubmucosa
nodes
rxLev+5FU
surglong



Riesgos proporcionales.

```
##          chisq df     p
## rx     0.67867  1 0.410
## adhere 0.00747  1 0.931
## nodes  0.00112  1 0.973
## extent 6.56092  3 0.087
## surg   0.02595  1 0.872
## GLOBAL 7.30176  7 0.398
```